Diagnóstico de qualidade dos dados

Projeto de migração de ERP para AWS · sprints 1 a 10 (set/2024 a jan/2025) · fonte: dataset_artefato/ (dados brutos)

Por que este relatório existe. Antes de responder às perguntas de sobrecarga e silos, os quatro arquivos foram auditados para saber em quais números é possível confiar. O resultado orienta as premissas da análise e a limpeza registrada em dataset_limpo/LIMPEZA.md.

Prompt usado na ferramenta de IA: "Anexei 4 CSVs de um projeto (tarefas, time, backlog, atas). Descreva cada arquivo e liste problemas de qualidade: valores faltantes, linhas vazias, sprints sem ata, e números que não batem entre arquivos (ex.: velocity do backlog vs. story points concluídos nas tarefas). Liste as premissas que você precisa assumir."

1. Os quatro arquivos

Arquivo	Linhas	Colunas	O que registra
dataset_tarefas.csv	120 tarefas	21	Uma linha por tarefa: tipo, responsável, story points, datas previstas e reais, status, dependências, impedimentos, mudança de escopo, retrabalho, horas e custo.
dataset_time.csv	6 pessoas	16	Papel, senioridade, especialidade, capacidade semanal, % de utilização por sprint e custo/hora.
dataset_backlog.csv	10 sprints	10	Resumo por sprint: itens no início, adicionados, concluídos e no fim; velocity; impedimentos; tarefas com mudança de escopo e com retrabalho.
dataset_atas.csv	8 reuniões	5	Dailies e retrospectivas: sprint, tipo, data, participantes e resumo em texto.

Pessoa	Papel	Pessoa	Papel
Ana	Tech Lead	Diego	Analista de Dados
Bruno	Dev Backend	Elena	QA
Carla	Dev Frontend	Felipe	PM / Scrum Master

Situação das tarefas: **93 concluídas**, 21 em andamento e 6 a fazer.

2. Problemas de qualidade

2.1 Valores faltantes

Arquivo	Campo	Linhas afetadas	Avaliação
tarefas	horas_gastas e custo_real	4 tarefas concluídas (TASK-031, 055, 085, 092)	**Problema.** Tarefa concluída deveria ter horas; fica fora das somas de horas e custo.
tarefas	impedimentos	3 tarefas concluídas (TASK-023, 038, 082)	**Problema.** Não se sabe se é zero ou falta de registro.
tarefas	data_inicio_real	8: as 6 "To Do" e 2 "Done" (TASK-040, 081)	Esperado nas "To Do"; **problema** nas 2 concluídas.
tarefas	data_fim_real	21	Esperado: tarefas não concluídas.
tarefas	dependencias	36	Esperado: tarefas sem dependência.

2.2 Valores incoerentes dentro do mesmo arquivo

- **Datas de fim em tarefas abertas:** 6 tarefas "In Progress" têm data_fim_real preenchida (TASK-065, 066, 067, 071, 113, 114).
- **Dependência fora de ordem:** TASK-113 (sprint 9) depende de TASK-074, que é da sprint 10.
- **Saldo do backlog quebrado entre sprints:** dentro de cada sprint a conta fecha (início + adicionados - concluídos = fim), mas o fim de uma sprint não bate com o início da seguinte (sprint 1 termina com 6 itens e a 2 começa com 14; a 8 termina com 19 e a 9 começa com 24).

2.3 Linhas vazias, colunas sem valor e redundantes

- **Ata da sprint 3** (Retrospectiva, 27/09/2024): sem participantes nem resumo, e com 6 campos em vez de 5.
- **Atas fora de ordem:** a sprint 5 aparece antes da 4.
- **Coluna constante:** horas_semana_disponiveis vale 40 para todos.
- **Coluna redundante:** custo_hora_responsavel repete o custo_hora do time em 100% das linhas.

2.4 Sprints sem ata e ausências

Sprint	Situação das atas
3	Linha existe, mas está vazia.
7 e 10	Sem ata.
1, 4, 5 e 8	Só daily, sem retrospectiva.
2, 6 e 9	Só retrospectiva, sem daily.

Ausências registradas: **Bruno e Carla** faltaram às dailies das sprints 5 e 8 (só 4 de 6 participantes).

2.5 Números que não batem entre arquivos

a) Velocity (backlog) × story points concluídos (tarefas) — os arquivos apontam tendências opostas.

Sprint	1	2	3	4	5	6	7	8	9	10
Velocity no backlog	28	30	32	29	27	26	24	22	20	12
SP concluídos nas tarefas	32	34	48	46	49	59	66	91	27	0

O backlog diz que a entrega cai; as tarefas dizem que sobe até a sprint 8. A sprint 10 tem velocity 12 no backlog, mas nenhuma tarefa concluída.

b) Impedimentos — possivelmente medem coisas diferentes (impedimentos únicos × ocorrências por tarefa), mas os arquivos não dizem.

Sprint	1	2	3	4	5	6	7	8	9	10
Abertos (backlog)	1	2	3	3	5	8	10	13	14	12
Soma por tarefa (tarefas)	1	1	4	3	8	14	18	28	29	23

c) Mudança de escopo e retrabalho (sprints com divergência)

Sprint	Escopo (backlog)	Escopo (tarefas)	Retrabalho (backlog)	Retrabalho (tarefas)
3	1	0	1	1
6	4	5	2	4
8	5	5	4	6
9	4	5	3	5
10	4	5	2	1

- **d) Itens × tarefas:** o backlog registra 8 itens concluídos por sprint até a sprint 8, enquanto as tarefas concluídas variam de 8 a 14. O backlog começa com 14 itens e a sprint 1 tem 8 tarefas: não fica claro se "item" é o mesmo que "tarefa".
- **e) Utilização (time) × horas gastas (tarefas):** na sprint 9, Ana aparece com 128% de utilização, mas tem 172 h gastas nas tarefas, o que daria 215% de uma capacidade de 80 h por sprint. Diego: 110% contra 170 h na sprint 8.
- **f) Atas × dados:** na retrospectiva da sprint 9, Elena diz que "40% das tarefas" voltaram por retrabalho; as tarefas mostram 31% (5 de 16).

3. Premissas adotadas

#	Premissa	Justificativa
1	Sprint de 2 semanas.	As atas têm cerca de 14 dias de intervalo. As tarefas das sprints 1 e 2 cabem em 1 semana cada, então é preciso confirmar.
2	Capacidade de 40 h/semana (80 h/sprint) por pessoa.	Vem de horas_semana_disponiveis.
3	Fonte única para entregas, escopo e retrabalho: dataset_tarefas.	É o mais detalhado e auditável linha a linha. O backlog fica só para a evolução de itens e impedimentos abertos.
4	Fonte para sobrecarga: dataset_time.	A utilização é coerente com as atas (Ana: "50+ horas por semana", cerca de 125%). As horas das tarefas provavelmente incluem trabalho que atravessa sprints.
5	Campo em branco = desconhecido, não zero.	Nenhum valor foi preenchido por estimativa.
6	Tarefa "In Progress" não está concluída, mesmo com data de fim.	A data de fim é ignorada.
7	A sprint 10 está em andamento.	Entra na previsão, mas não nas médias de desempenho.
8	As atas são uma amostra, não um registro completo.	Ausência em reunião sinaliza silo, mas não prova ausência na sprint inteira.
9	Custo = horas × custo/hora, sem encargos ou indiretos.	A conta foi confirmada em 100% das linhas.

4. O que isso muda na análise

- A divergência de velocity é o achado mais importante: dependendo da fonte, o projeto parece acelerar ou desacelerar. Toda conclusão sobre ritmo de entrega precisa dizer qual fonte usou e por quê.
- Sobrecarga será medida pela utilização do dataset_time, confirmada pelo que as atas relatam, e não pelas horas somadas das tarefas.
- As limpezas aplicadas (colunas redundantes e constantes, ata vazia, datas de fim em tarefas abertas) estão em dataset_limpo/ e documentadas em dataset_limpo/LIMPEZA.md, geradas por scripts/limpar_dados.py.